

# BIG DATA

PROYECTO FINAL

Juan David Collazos González

(tu foto)



# JUAN DAVID COLLAZOS GONZÁLEZ

RESPONSABLE DEL DESARROLLO DE LA APLICACIÓN

Fecha: 03 de julio de 2026

## DESARROLLO

### 1. Introducción y escenario

---

Como analista de Big Data en Tokio Telecom, el objetivo de este proyecto es analizar un conjunto de datos de clientes de telefonía móvil y su baja de servicio (churn) para extraer conocimiento accionable y construir un modelo capaz de anticipar qué clientes abandonarán la compañía.

El conjunto de datos, `customer_churn_10k.csv`, contiene **10.000 registros y 12 campos**. La variable objetivo es `Churn_YesNo` (Yes = el cliente se ha dado de baja). El análisis se ha desarrollado con Apache Cassandra (almacenamiento y consultas CQL) y con PySpark sobre Google Colab (análisis descriptivo, correlación y aprendizaje automático).

**Nota metodológica:** todos los resultados numéricos y gráficos de este informe se han obtenido ejecutando el código PySpark recogido en el documento técnico y en el notebook entregable (`churn_pyspark_colab.ipynb`). Las cifras son, por tanto, reproducibles.

## 2. Tarea 1 — Estructura y tipos de datos

El primer paso consiste en conocer con qué datos contamos, clasificando cada campo según su naturaleza estadística.

| Nombre del Campo  | Tipo de dato                       |
|-------------------|------------------------------------|
| CustomerID        | Categorico nominal (identificador) |
| Age               | Numérico discreto                  |
| Gender            | Categorico nominal                 |
| Tenure            | Numérico discreto                  |
| Usage Frequency   | Numérico discreto                  |
| Support Calls     | Numérico discreto                  |
| Payment Delay     | Numérico discreto                  |
| Subscription Type | Categorico nominal                 |
| Contract Length   | Categorico ordinal                 |
| Total Spend       | Numérico continuo                  |
| Last Interaction  | Numérico discreto                  |
| Churn_YesNo       | Categorico binario                 |

**Decisión de análisis relevante:** aunque `CustomerID` se almacena como número, es un identificador y debe tratarse como variable **categorica**. No tiene sentido calcular su media ni su correlación y se excluye de todos los modelos, tal como indica el enunciado. `Contract Length` es categorica ordinal (Monthly < Quarterly < Annual) y `Total Spend` es la única variable continua.

## 3. Tarea 2 — Almacenamiento y consultas en Cassandra

Con la interfaz `cqlsh`, se preparó la estructura en Apache Cassandra y se insertaron los 10.000 registros para ejecutar las consultas solicitadas. Los comandos completos se recogen en el fichero `comandos_cassandra.txt`.

### 3.1 Entorno de trabajo: Cassandra sobre Docker

Cassandra se ejecutó en un contenedor Docker local, de modo que el entorno es totalmente reproducible sin instalar Cassandra en el sistema anfitrión. La secuencia fue: levantar el contenedor, copiar el CSV en su interior, abrir cqlsh, crear el keyspace y la tabla, e importar los datos.

```
# Levantar Cassandra en un contenedor Docker
docker run --name cassandra-tokio -p 9042:9042 -d cassandra:5.0

# Copiar el CSV dentro del contenedor e importarlo
docker cp customer_churn_10k.csv cassandra-tokio:/customer_churn_10k.csv
docker exec -it cassandra-tokio cqlsh
```

Estructura creada — keyspace `telecom_analytics` y tabla `customer_churn` (con `CustomerID` como clave primaria e índices secundarios sobre las columnas de filtrado):

```
CREATE KEYSPACE telecom_analytics WITH replication =
  {'class': 'SimpleStrategy', 'replication_factor': '1'} AND durable_writes =
  true;

CREATE TABLE telecom_analytics.customer_churn (
  "CustomerID" double PRIMARY KEY, "Age" double, "Gender" text,
  "Tenure" double, "Usage Frequency" double, "Support Calls" double,
  "Payment Delay" double, "Subscription Type" text, "Contract Length" text,
  "Total Spend" double, "Last Interaction" double, "Churn_YesNo" text);

CREATE INDEX idx_contract_length ON telecom_analytics.customer_churn ("Contract
Length");
CREATE INDEX idx_subscription_type ON telecom_analytics.customer_churn
("Subscription Type");

COPY telecom_analytics.customer_churn (...) FROM '/customer_churn_10k.csv' WITH
HEADER = TRUE;
```

### 3.2 Consulta a) Recuperar todos los registros de la tarifa Basic

```
SELECT * FROM telecom_analytics.customer_churn
WHERE "Subscription Type" = 'Basic' ALLOW FILTERING;

SELECT COUNT(*) FROM telecom_analytics.customer_churn
WHERE "Subscription Type" = 'Basic' ALLOW FILTERING;

count
-----
3233
```

**Resultado:** existen **3.233 clientes** con tarifa Basic (verificado también sobre el CSV).

### 3.3 Consulta b) Recuperar todos los registros Basic con contrato anual

```
SELECT * FROM telecom_analytics.customer_churn
WHERE "Subscription Type" = 'Basic' AND "Contract Length" = 'Annual' ALLOW
FILTERING;

SELECT COUNT(*) FROM telecom_analytics.customer_churn
WHERE "Subscription Type" = 'Basic' AND "Contract Length" = 'Annual' ALLOW
```



```
FILTERING;
```

```
count
```

```
-----
```

```
1250
```

**Resultado:** de los clientes Basic, **1.250** tienen además contrato anual (el resto: 1.337 trimestral y 646 mensual).

## 4. Tarea 3 — Clientes y churn por categoría (PySpark)

Cargados los datos en un DataFrame de PySpark, se calcula para cada tipo de tarifa y cada duración de contrato el número de clientes y el porcentaje que ha hecho churn (% de “Yes”).

### 4.1 Churn por tipo de tarifa (Subscription Type)

| Subscription Type | Clientes | Churn (Yes) | % Churn |
|-------------------|----------|-------------|---------|
| Basic             | 3.233    | 1.884       | 58,3 %  |
| Standard          | 3.361    | 1.905       | 56,7 %  |
| Premium           | 3.406    | 1.883       | 55,3 %  |




Figura 1. N° de clientes y % de churn por tipo de tarifa.

### 4.2 Churn por duración del contrato (Contract Length)

| Contract Length | Clientes | Churn (Yes) | % Churn |
|-----------------|----------|-------------|---------|
| Monthly         | 1.984    | 1.984       | 100,0 % |
| Quarterly       | 3.970    | 1.865       | 47,0 %  |
| Annual          | 4.046    | 1.823       | 45,1 %  |




Figura 2. N° de clientes y % de churn por duración del contrato.

### 4.3 Interpretación de negocio

- **El tipo de tarifa apenas discrimina la baja:** las tres tarifas presentan un churn alto y similar (55–58 %). No es una palanca de retención por sí sola.
- **La duración del contrato sí es determinante:** el contrato mensual concentra un **100 % de bajas**, frente al ~47 % del trimestral y ~45 % del anual. El compromiso de permanencia es el factor de retención más potente.
- **Recomendación:** incentivar la migración de clientes mensuales hacia contratos trimestrales o anuales, donde la baja se reduce a menos de la mitad.

## 5. Tarea 4 — Análisis descriptivo (PySpark)

Se calcula la media y la desviación estándar de cada variable numérica (se excluye CustomerID por ser categórica). Se añaden mínimo y máximo para dimensionar el rango.

| Variable         | Media  | Desv. estándar | Mín | Máy  |
|------------------|--------|----------------|-----|------|
| Age              | 39,26  | 12,49          | 18  | 65   |
| Tenure           | 30,95  | 17,14          | 1   | 60   |
| Usage Frequency  | 15,77  | 8,63           | 1   | 30   |
| Support Calls    | 3,59   | 3,08           | 0   | 10   |
| Payment Delay    | 13,03  | 8,26           | 0   | 30   |
| Total Spend      | 633,32 | 240,47         | 100 | 1000 |
| Last Interaction | 14,49  | 8,62           | 1   | 30   |

### 5.1 Interpretación

- **Edad** media de 39 años (rango 18–65): base de clientes adulta y amplia.
- **Tenure** media de 31 meses con desviación muy alta ( $\pm 17$ ): conviven clientes nuevos y veteranos.
- **Support Calls** (media 3,6) y **Payment Delay** (media 13 días) son variables de fricción con recorrido: señales tempranas de insatisfacción.
- **Total Spend** medio de 633 € ( $\pm 240$ ): gran heterogeneidad de valor entre clientes, que justifica una segmentación.



## 6. Tarea 5 — Análisis de correlación (PySpark)

Para obtener la matriz de correlación fue necesario configurar las columnas con el tipo adecuado (cast a double) y ensamblar las variables numéricas en un único vector con `VectorAssembler`, requisito de `Correlation.corr` (coeficiente de Pearson).




Figura 3. Matriz de correlación de Pearson entre variables numéricas.

### 6.1 Correlación de cada variable con la baja

Añadiendo una columna `churn01` (Yes = 1) medimos su correlación con cada variable:

| Variable         | Correlación con churn |
|------------------|-----------------------|
| Support Calls    | <b>+0,58</b>          |
| Payment Delay    | <b>+0,32</b>          |
| Age              | +0,23                 |
| Last Interaction | +0,15                 |
| Tenure           | -0,05                 |
| Usage Frequency  | -0,07                 |
| Total Spend      | <b>-0,42</b>          |

### 6.2 Interpretación

- **Baja multicolinealidad:** entre variables numéricas las correlaciones son muy débiles ( $|r| < 0,25$ ), lo que es positivo: cada variable aporta información propia a un modelo.



- **Principales impulsores de la baja:** Support Calls (+0,58), Payment Delay (+0,32) y Age (+0,23).
- **Principal factor de retención:** Total Spend (−0,42): a mayor gasto, menor baja.

## 7. Tarea 6 — Modelo de aprendizaje supervisado (PySpark)

### 7.1 Problema de negocio y elección del algoritmo

El problema —anticipar qué clientes se darán de baja— es de **clasificación binaria supervisada**, porque disponemos de la etiqueta real (Churn\_YesNo). Predecir la baja antes de que ocurra permite activar campañas de retención sobre los clientes en riesgo: es más barato retener que captar.

Se comparan dos modelos basados en árboles —un Árbol de Decisión, interpretable y que produce reglas directas, y un Random Forest, ensemble que reduce la varianza y mejora la capacidad predictiva— junto con una Regresión Logística como baseline lineal. Los tres se ajustan mediante Grid Search con validación cruzada de 5 particiones (CrossValidator de Spark ML), optimizando el AUC en lugar de la accuracy: en un problema de baja el coste es asimétrico (perder un cliente es más caro que un incentivo) e interesa ordenar a los clientes por riesgo, algo que la accuracy —atada a un umbral fijo— no captura.

### 7.2 Preparación de los datos (procesado de categóricas)

Las variables categóricas Gender, Subscription Type y Contract Length se transforman con StringIndexer y OneHotEncoder. Se unen con las numéricas mediante VectorAssembler (más StandardScaler para la Regresión Logística) dentro de un Pipeline. Partición **70 % entrenamiento / 30 % test** (semilla 42).

### 7.3 Resultados y comparación de modelos

| Modelo              | AUC (CV) | AUC train | AUC test      | Recall baja (test) | F1 (test) |
|---------------------|----------|-----------|---------------|--------------------|-----------|
| Árbol de Decisión   | 0,9943   | 0,9996    | <b>0,9982</b> | 0,997              | 0,995     |
| Random Forest       | 0,9994   | 1,0000    | <b>0,9997</b> | 0,990              | 0,992     |
| Regresión Logística | 0,9599   | 0,9602    | <b>0,9583</b> | 0,896              | 0,895     |




Figura 4. Curvas ROC en train y en test para cada modelo.




Figura 5. Matrices de confusión sobre el conjunto de test (modelos afinados).

El Random Forest, afinado con Grid Search + validación cruzada, es el mejor modelo: AUC de 1,0000 en train y 0,9997 en test; el Árbol de Decisión queda muy cerca (0,9996 / 0,9982) y la Regresión Logística por detrás (0,9602 / 0,9583). Que el AUC en train  $\approx$  test descarta el sobreajuste. En test, el Random Forest solo comete 7 falsos positivos y 16 falsos negativos sobre 2.896 clientes, frente a los 171 falsos negativos de la Regresión Logística: por eso la accuracy no es la métrica adecuada y se reporta el AUC junto al recall de la clase baja. El AUC cercano a 1 no es un artefacto, sino reflejo de que el conjunto (sintético) contiene patrones casi deterministas —por ejemplo, el contrato mensual conlleva un 100 % de baja—.

## 7.4 Importancia de variables




Figura 6. Importancia relativa de variables (Random Forest afinado).

El modelo confirma lo visto en la correlación: las variables que más pesan son Support Calls (0,31), Total Spend (0,22), Age (0,13) y Payment Delay (0,12). Las conductuales dominan sobre las contractuales.

## 7.5 Conclusiones del modelo

- Se dispone de un modelo (Random Forest) con capacidad predictiva muy alta, listo como sistema de alerta temprana de churn.
- **Perfil de cliente en riesgo:** muchas llamadas a soporte, retrasos de pago y bajo gasto acumulado.
- **Acción:** priorizar la retención sobre los clientes con alta probabilidad de baja, en especial los de contrato mensual.

## 8. Próximos pasos y trabajo futuro

El proyecto deja varias líneas de continuación para llevar el modelo de un entorno de laboratorio a producción:

- Validación temporal (out-of-time): entrenar con un periodo y validar con el siguiente, más exigente que el reparto aleatorio y más fiel al comportamiento en despliegue.
- Recalibración de probabilidades y elección del umbral por coste, a partir de una matriz de coste real (valor del cliente frente a coste del incentivo), en lugar del umbral 0,5.
- Probar modelos de boosting (Gradient-Boosted Trees de Spark, XGBoost) y compararlos con los actuales.
- Explicabilidad con valores SHAP para justificar cada predicción ante el equipo de retención.



- Ingeniería de variables: ratios (gasto por antigüedad), tendencias de uso e incidencias por mes.
- Industrialización: pipeline Spark reentrenable y programado, scoring por lotes exportado al CRM y monitorización de data drift.
- Validación de negocio (A/B): medir si la campaña de retención sobre el top-N de riesgo reduce realmente la tasa de baja.

## CONCLUSIONES

El proyecto ha recorrido el ciclo completo de un análisis de Big Data sobre la base de clientes de Tokio Telecom: desde el almacenamiento de los datos (Cassandra sobre Docker) hasta la explotación analítica y predictiva (PySpark). Las conclusiones principales son:

- La compañía tiene un churn global elevado (56,7 %), lo que hace de la retención una prioridad estratégica.
- El contrato mensual es el mayor factor de riesgo (100 % de baja); la permanencia trimestral/anual lo reduce a menos de la mitad.
- Las llamadas a soporte y los retrasos de pago anticipan la baja, mientras que un mayor gasto la previene.
- El modelo Random Forest, entrenado con selección de hiperparámetros y validación cruzada, predice la baja con un AUC de 0,9997 en test y sin sobreajuste, convirtiendo el análisis en una herramienta operativa de retención.

**Recomendación final:** integrar el modelo en un flujo de alerta temprana acompañado de acciones diferenciadas —migración de contratos mensuales, atención proactiva a clientes con alta carga de soporte y fidelización de clientes de bajo gasto.